


ANÁLISIS DE REGRESIÓN LINEAL SIMPLE




Regresión lineal



El análisis de regresión nos proporciona un método que nos permite encontrar un modelo matemático, si es que existe, que vincule a las variables. Es decir, nos propone una función que relacione ambas variables. Puede ser una función Lineal, cuadrática, exponencial, etc.

A la variable que queremos explicar la llamaremos variable dependiente o explicada y la notaremos con la letra “y”, a la otra variable la llamaremos variable independiente o regresora y la notaremos con la letra “x”

Como primer paso analizaremos, cuál debería ser el método más acorde, para ello se realiza un dispersograma o diagrama de dispersión o nube de puntos ¿cómo? A partir de la muestra hallada se grafican los pares ordenados (x,y) en un sistema de ejes cartesianos. Y se observa la forma de la nube de puntos. Miremos los siguientes



PATRICIA ARNAL



Regresión Lineal Simple

Mediante este modelo se trata de encontrar una función lineal que vincule a las variables.

Función lineal: $y = \alpha + \beta x$

Elementos:

y: variable explicada o dependiente x: variable explicativa o independiente

α : ordenada al origen, donde se interseca con el eje y, o sea cuando $x = 0$

β : pendiente de la recta, tasa o coeficiente de regresión

Este modelo lineal es un modelo determinístico, ya que al sustituir un valor de "x" en la ecuación el valor de "y" queda determinado y no se considera margen de error, es decir este modelo no tiene componente aleatoria. Para tomar en cuenta el error aleatorio, inexplicado e imprevisible de la predicción el modelo probabilístico es:

$y = \alpha + \beta x + \varepsilon$ donde ε es una componente aleatoria que se denomina el ruido del modelo.

Suponiendo que la media de las componentes aleatorias es cero entonces nos queda: que la media de y, para un valor de x es: $\mu(y/x) = \alpha + \beta x$


Esta es la función lineal poblacional, donde α y β son los parámetros del modelo.



Como los parámetros son desconocidos, debemos trabajar con valores muestrales, y en vez de trabajar con la recta poblacional trabajamos con la recta muestral.

Recta de regresión muestral: $\hat{y} = a + bx$; esta recta es una estimación de la poblacional, donde a es la ordenada al origen de la recta muestral, llamada también intercepto y estima a α ; b es la pendiente de la recta muestral, llamada también coeficiente de regresión y estima a β el modelo probabilístico es

$y = \hat{y} + e \rightarrow e = y - \hat{y}$ esta diferencia se conocido como el error.



El valor observado es y ; el valor estimado es el que se obtiene en la recta, es decir $\hat{y}$



El método para encontrar la recta de regresión se denomina: Método de cuadrados mínimos
El método de los mínimos cuadrados, consiste en elegir la función que minimiza la suma de los cuadrados de los residuos o errores

Por ahí lo más lógica sería minimizar la suma de los errores, pero $\sum e = \sum (y - \hat{y}) = 0$, pero como la recta es de promedios esto se cumple siempre, entonces la solución propuesta es minimizar la suma de los errores al cuadrado, es decir, $\sum e_i^2$ es mínima

Al resolver matemáticamente esta condición, se obtienen fórmulas para los dos parámetros de la recta:

$$b = \frac{\sum x.y - n \bar{x} \bar{y}}{\sum x^2 - n \bar{x}^2} \quad a = \bar{y} - b \bar{x}$$

Interpretación de los parámetros (genérica)

Interpretación de **a**:

Es el valor medio de y cuando x es cero, este valor puede no tener sentido o no ser confiable.

Interpretación general de **b**

Indica cuanto varía en promedio y (aumenta o disminuye según el signo) por cada unidad que se incrementa x



Práctico 9 - Ejercicio 1

En una empresa de desarrollo de software, se desea analizar si es posible estimar la cantidad de errores de programación detectados en el código en función de las horas semanales dedicadas a la codificación. El equipo de desarrollo sospecha que los programadores que dedican más horas a trabajar en los proyectos podrían cometer menos errores debido a la mayor familiaridad con el código, mientras que los que dedican menos tiempo podrían generar más errores. Se tomaron los siguientes registros:

Horas semanales	12	12	15	16	17,5	18	22
Errores	5	4	3	2	3	2	1

- Determinar la variable dependiente y la independiente
- Realizar el diagrama de dispersión y analizar si le parece que una recta ajusta bien a los datos.
- Hallar la recta de regresión e interpretar en términos del problema sus coeficientes (a y b)
- Realizar una estimación para la cantidad media de errores que tendrán los códigos cuando se dedicaron 18hs semanales. Comparar con el valor observado y calcule el residuo e interpretarlo.
- Estimar la cantidad media de errores que tendrán los códigos cuando el tiempo semanal que le dedicó a la programación fue de 20hs. ¿y si llevó 30hs?




Resolución

a)

x: horas semanales dedicadas a la elaboración de los códigos.

y: cantidad de errores detectados de programación.

b) Una recta aproxima bien a los datos




c) Resolvemos con Jamovi.

Ingresa los datos (una columna para x y otra para y) → Exploración → Gráfico de dispersión

Nos genera el gráfico de dispersión

Gráfico de dispersión

Horas	Errores
12	5
12	4
15	3
16	2
17,5	3
18	2
22	1



c) Para hallar la recta de regresión: Análisis → Regresión → regresión lineal

Pasamos las variables, dependientes y covariables (independientes)

Nos devuelve

Medidas de Ajuste del Modelo

Modelo	R	R ²
1	0.907	0.823

Nota. Models estimated using
sample size of N=7

Coeficientes del Modelo - Errores

Predictor	Estimador	EE	t	p
Constante a	8.397	1.1716	7.17	< .001
Horas b	-0.345	0.0714	-4.83	0.005

La recta de regresión es: $\hat{y} = 8,3974 - 0,3447 x$



Recordemos:

x: horas semanales dedicadas a la elaboración de los códigos.

y: cantidad de errores detectados de programación.

El coeficiente **a** es el valor medio de **y** cuando **x** es cero

El coeficiente **b** indica cuanto varía **y** (aumenta o disminuye según el signo) por cada unidad que se incrementa **x**

$$\hat{y} = 8,397 - 0,345 x$$

Interpretación de **a=8,397** cuando no se dedican horas a la elaboración de códigos la cantidad media de errores en la programación se estima en 8,397. Este resultado no tiene sentido

Interpretación de **b=0,345** por cada hora más que se dedique a la elaboración de los códigos, la cantidad media de errores en la programación disminuye en 0,345 en promedio.



d) Realizar una estimación para la cantidad media de errores que tendrán los códigos cuando se dedicaron 18hs semanales. Comparar con el valor observado y calcule el residuo e interpretarlo.

$$\hat{y}(18) = 8,397 - 0,345 \cdot 18 = 2,187$$

$$\text{Residuo: } e = 2 - 2,187 = -0,187$$

este valor significa que la observación está por debajo de la recta, es decir, que se sobreestimó en 0,187

e) Estimar la cantidad media de errores que tendrán los códigos cuando el tiempo semanal que le dedicó a la programación fue de 20hs. ¿y si llevó 30hs?

$$\hat{y}(20) = 8,397 - 0,345 \cdot 20 = 1,497$$

Para $x=30$ no tiene sentido estimar ya que la x toma valores entre 12 y 22.




VALIDACIÓN DEL MODELO

ANÁLISIS DE CORRELACIÓN LINEAL

El análisis de regresión lineal nos permite encontrar el mejor modelo dentro de los lineales. Pero ¿es bueno es este modelo para pronosticar? Para contestar a esta pregunta tendremos que analizar la bondad de ajuste del modelo a través del análisis de correlación. El análisis de correlación trata de ver si el modelo es apto para predicciones y en tal caso describir el grado de asociación entre las variables.

Muchas veces el gráfico puede perder la precisión que necesitamos, por lo que es necesario un procedimiento que nos permita analizar la validez del modelo en cuanto a su aptitud para realizar pronósticos; necesitamos una medida que nos permita determinar qué tan bien se ajusta el modelo lineal al conjunto de datos.



$SCT = SCR + SCE \rightarrow \sum (y - \bar{y})^2 = \sum (y - \hat{y})^2 + \sum (\hat{y} - \bar{y})^2$ si dividimos por la SCT, obtenemos:

$1 = \frac{\sum (y - \hat{y})^2}{\sum (y - \bar{y})^2} + \frac{\sum (\hat{y} - \bar{y})^2}{\sum (y - \bar{y})^2}$ se trata que el modelo explique la mayor proporción, es decir que,

$$\frac{\sum (\hat{y} - \bar{y})^2}{\sum (y - \bar{y})^2} \rightarrow 1$$

Este cociente es el coeficiente de determinación

Coeficiente de determinación: r^2

Es un indicador que se utiliza para calificar un modelo lineal y mide la proporción o porcentaje de la variación total de la variable “y” explicada por el modelo de regresión a través de las variaciones de “x”

Es decir r^2 mide la proporción o porcentaje de la variación total explicada por el modelo de regresión.

Propiedades:

1) $r^2 \geq 0$

2) $0 \leq r^2 \leq 1$

Si $r^2 = 1$ el ajuste de los datos es perfecto al modelo, la nube de puntos coincide con la recta de regresión.

Si $r^2 = 0$ no hay relación estadística entre la variable dependiente y la independiente

- la nube de puntos está totalmente dispersa con respecto a la recta
- el modelo (en este caso lineal) no se ajusta a los datos observados

Nota: habitualmente si $r^2 < 0,50$ el modelo no se considera bueno para pronósticos.

Coeficiente de correlación lineal muestral: r

Es una medida del grado o intensidad e indica el sentido de la "asociación lineal entre las variables.

Propiedades

1) $-1 \leq r \leq 1$

$r = 1$ quiere decir que existe una total asociación o dependencia lineal positiva entre x e y

$r = -1$ quiere decir que existe una total asociación o dependencia lineal negativa entre ambas variables

2) El signo de r es el mismo que el de b

3) Si x e y son independientes entonces $r = 0$

Si $r = 0$ no implica que x e y sean independientes, puede ser que sean dependientes pero no responden a un modelo lineal

4) r es un indicador lineal

Consideramos. si $|r| > 0,7$, es un buen modelo para pronósticos.

Ejemplo 1

Una empresa desea saber si es posible estimar el tiempo que pasan en las redes sociales los usuarios en función de la edad del mismo. Para ello seleccionó una muestra de 17 usuarios de redes sociales entre 25 y 50 años y se obtuvo:

$$r = -0,864$$

- a) Determinar las variables x e y
- b) Interpretar el coeficiente de correlación lineal
- c) Interpretar el coeficiente de determinación.
- d) ¿Puede concluir que el modelo lineal es bueno para realizar estimaciones?

Resolución

- a) X : edad del usuario y : tiempo en las redes sociales (hs)
- b) Existe una fuerte asociación lineal entre la edad del usuario y el tiempo que pasa en las redes sociales
- c) $r^2 = (-0,864)^2 = 0,7465 \rightarrow$ El 74,65% de las variaciones en el tiempo de uso de las redes sociales se explican a través de las variaciones en la edad del usuario.
- d) Es un modelo apto para pronósticos; porque $|r| > 0,7$

Práctico 9 - Ejercicio 6

Decidir, justificando la elección cuál de los siguientes coeficientes corresponde a cada gráfico: $r^2=0.88$, $r=0.30$, $b= -5$




Gráfico 1




Gráfico 2




Gráfico 3

PRUEBA DE HIPÓTESIS PARA EL COEFICIENTE DE REGRESIÓN (β)

Si la recta de regresión poblacional tiene pendiente: $\beta=0$ significa que es horizontal o sea (cte.) entonces los valores de x no servirían para predecir y , pues no importa que valor toma x el valor de y se mantiene constante; es decir no varía.

Conclusión, para determinar si el uso de la recta mejora o no la estimación de los valores de y debemos plantear las hipótesis: $H_0: \beta = 0$ $H_1: \beta \neq 0$

Rechazar H_0 significa llegar a la conclusión de que la recta de regresión es útil para estimar la variable dependiente, es decir, que las variables están linealmente asociadas.

Al tener como datos solo resultados muestrales el trabajo es análogo al estudiado cuando se infería acerca de la media con desvío desconocido.

En el ejemplo de las redes sociales : si sabemos que $p-v=0,032$ y consideramos $\alpha=0,05$.

$H_0: \beta = 0$ $H_1: \beta \neq 0$ CR: $\{\alpha > p-v\}$

Se verifica la CR $\rightarrow$ RHo; entonces podemos concluir que la edad del usuario y el tiempo de uso de las redes están linealmente asociadas, con un nivel de significación del 5%

Ejemplo 2

Se realiza un estudio para estimar el gasto mensual de usuarios en servicios digitales (como suscripciones a plataformas de streaming, videojuegos online, cursos en línea, etc.) en función del ingreso mensual de los usuarios. Una muestra de diez usuarios de diferentes plataformas digitales proporciona la siguiente información (todo en miles de pesos):

Ingreso	1624	1855	1930	2270	2635	2910	3140
Gasto	28	32	35	32	37	40	42

- a) Hallar la recta de regresión e interpretar los coeficientes de la recta en términos del problema.
- b) ¿Muestran los datos evidencias suficientes para concluir que el nivel de ingreso familiar y los gastos están linealmente asociados? Considerar un nivel de significación del 1% y $S_b = 0,001415$.
- a) Interpretar en términos del problema el coeficiente de determinación. Este valor ¿ratifica o rectifica la decisión tomada en b?



Resolución

Igual que hacemos para hallar la recta de regresión, ingresamos los datos y donde nos devuelve la recta, también tenemos r y r^2

a) Hallar la recta de regresión e interpretar los coeficientes de la recta en términos del problema.

$$\hat{y} = 16,516 + 0,008 x$$

Interpretación de a: En esta situación no tiene sentido, pues representa que, cuando la familia no tiene ingresos destina en promedio \$16.516 gastos de servicios digitales.

Interpretación b: Por cada mil pesos que aumenta el ingreso familiar el gasto en servicios digitales aumenta en promedio \$8.



b) ¿Muestran los datos evidencias suficientes para concluir que el nivel de ingreso familiar y los gastos están linealmente asociados? Considerar un nivel de significación del 6% y $S_b=0,001415$.

$$H_0: \beta = 0 \quad H_1: \beta \neq 0$$

Resolución con fórmula: Calculamos $t_m = \frac{b}{S_b} = \frac{0,008}{0,001415} = 5,6537$

$$v = 2 * P(t > |t_m|) = 2 * P(t > 5,6537; gl=5) = 2 * 0,0012 = 0,0024$$

CR: $p_v < \alpha$ como $p_v = 0,0024 < 0,01$ se verifica CR entonces se rechaza H_0
Se concluye que el ingreso familiar y el gasto en servicios digitales están linealmente asociados con una probabilidad de error del 1%

Resolución con Jamovi

Donde nos devuelve los coeficientes de la recta
nos da también el valor t_m y el p_v

Coeficientes del Modelo - Gasto				
Predictor	Estimador	EE	t	p
Constante	16.516	3.380	4.887	0.0045
Ingreso	0.008	0.001	5.652	0.0024



c) Interpretar en términos del problema el coeficiente de determinación. Este valor ¿ratifica o rectifica la decisión tomada en b?

El Jamovi nos entrega el valor de r (R) y r^2 (R^2)

Medidas de Ajuste del Modelo		
Modelo	R	R^2
1	0.930	0.865

Nota. Models estimated using sample size of N=7

$r^2 = 0,865$. El 86,5% de las variaciones en el gasto en servicios digitales pueden explicarse por las variaciones en el ingreso familiar.

$r = 0,93$ lo que indica una intensa asociación lineal positiva o directa entre el ingreso familiar y el gasto en servicios digitales.

