


ESTADÍSTICA DESCRIPTIVA



ESTADÍSTICA.

La **estadística** es la ciencia que proporciona métodos para recopilar, organizar y resumir la información y utilizar esta información para obtener diversas conclusiones.

Trabaja siempre con fenómenos aleatorios.

Podemos dividirla en dos ramas



Estadística descriptiva: son los métodos que implican la recopilación, presentación y caracterización de un conjunto de datos con el fin de “describir” de manera apropiada las diversas características de dicho conjunto.

Estadística inferencial: proporciona métodos que hacen posible la estimación de una característica de una población o la toma de decisiones con respecto a una **población** a partir de los valores observados en una **muestra** extraída de dicha población.




A la fuente o área de donde son extraídos los datos se la conoce con el nombre de **población o universo**.

Población:


Es el conjunto totas de elementos sujetos a investigación, con características comunes, ya sean estos elementos personas, fenómenos entidades o cosas.

La población se define en relación con experimento o investigación que se va a realizar, sin importar la cantidad de elementos involucrados.



Muestra aleatoria:

Es un subconjunto de la población que posee las características más relevantes de dicha población. Debe ser representativa, en el sentido de contemplar toda la diversidad de la población.



Tipos de muestreo

Las muestras pueden ser probabilísticas o aleatorias y no probabilísticas.

En el caso de las **muestras probabilísticas** todos los elementos de la población tienen la misma posibilidad de ser elegidos, en cambio en las **no probabilísticas**, la elección de los elementos no depende de la probabilidad, sino de causas relacionadas con las características del investigador o del que hace la muestra. Elegir entre una u otra muestra depende de los objetivos del estudio, del esquema de investigación y de la contribución que se piensa hacer de ella.

Las muestras probabilísticas tienen muchas ventajas, quizás la principal es que puede medirse el tamaño de error de las predicciones y que permiten realizar inferencia estadística.

Una muestra probabilística puede obtenerse utilizando distintos métodos; Muestreo aleatorio simple – Muestreo sistemático – Muestreo estratificado – Muestreo por conglomerado, etc

En las muestras no probabilísticas, no podemos calcular con que nivel de confianza hacemos la estimación. Pero hay muchos casos en los que resulta ventajoso este tipo de muestreo

Una muestra no probabilística puede ser: Muestreo accidental – Muestreo de sujetos voluntarios- Muestreo de expertos, etc.



Proceso de investigación

Formular la hipótesis de investigación que definirán el tipo de experimento

Definir y clasificar las variables

Definir los sujetos que van a ser medidos delimitando la población y la muestra

Definir el tamaño de la muestra y elegir el método de recolección de datos

Elegir el instrumento de recolección de datos y aplicar el procedimiento de selección

Tabular los datos


Resumir los datos usando métodos estadísticos apropiados

Realizar un informe estadístico

En las **hipótesis de investigación** se formula aquello que estamos tratando de probar, pueden tratarse como explicaciones tentativas del fenómeno investigado.



Estudios



Práctico 1 – Ejercicio 1

Leer el siguiente estudio descriptivo referido a los cambios de hábitos de contenido audiovisual.

Un grupo de investigadores llevó a cabo un estudio para analizar cómo la aparición y evolución de las plataformas de streaming ha modificado los hábitos de consumo de contenido audiovisual.

Durante la última década, se realizó un seguimiento a 6200 personas de distintas edades (a partir de 20 años), género, nivel socioeconómico (bajo, medio, medio alto y alto) y nivel educativo (primario, secundario, superior) en 5 países distintos de Latinoamérica. Entre los distintos estudios realizados, se analizaron las siguientes relaciones: El aumento en el uso de plataformas de streaming y la disminución en la cantidad de audiencia de la televisión tradicional. La edad y la preferencia por consumir contenido en plataformas de streaming frente a medios tradicionales. El nivel socioeconómico y el tipo de suscripción elegida (gratuita con anuncios, estándar, Premium). El nivel educativo y la confianza en los algoritmos de recomendación de contenido.

- a) ¿Cuál es la población de estudio? ¿Y la muestra?
- b) ¿Cuál puede ser la hipótesis de trabajo?
- c) ¿Es un estudio longitudinal o transversal? ¿Por qué?



Variables aleatorias:

Una **variable aleatoria** es cualquier característica observable de los individuos que forman parte de la población o de la muestra en estudio.

Ejemplos:

- Número de huéspedes alojados en un período en establecimientos de primera categoría.
- Número de pacientes atendidos en una guardia un día seleccionado al azar
- Diagnóstico de los pacientes.
- Género



Clasificación de variables aleatorias

Cualitativas:

son aquellas cuyos resultados expresan categorías o atributos.

Cuantitativas:

son aquellas que expresan resultados numéricos.

Nominales: Su ordenamiento es arbitrario. No hay un criterio para ordenar las categorías.
(Estado civil; género; religión)

Ordinales: Poseen un ordenamiento intrínseco o natural.
(Máximo nivel de estudio; año de la carrera que cursan)

Discretas: son aquellas que asumen un número finito o infinito numerable de valores en un intervalo. En general surgen de procesos de conteo.
(Número de hijos; cantidad de materias aprobadas)

Continuas: son aquellas que pueden tomar cualquiera de los infinitos valores reales dentro de un intervalo. Surgen de proceso de medición
(Edad; Peso; Altura)



MEDICION DE VARIABLES

Variables Cualitativas

Escala nominal: para variables nominales (antes citadas)

Escala ordinal: para variables ordinales (antes citadas)

Variables Cuantitativas

Escala de intervalos

Escala de razón o proporción.



Escalas de intervalos: Existen orden y **jerarquía** entre las categorías, además se pueden establecer distancia entre una medida y otra. El **cero** en esta medición es **arbitrario**, es decir, no existe un punto de partida.

Por ejemplo: La temperatura; 0° C significa el nivel de congelación del agua (el cero es arbitrario) pero no significa que en 0° haya ausencia de temperatura.

Escala de razón o proporciones: Se diferencia de la escala de intervalo por la **inclusión** de un punto de partida, el cero no es arbitrario, es decir que en el punto cero no existe la característica que se mide. Aparte de esta diferencia, todas las demás características de la escala de intervalo se hallan presentes en la **escala** de razón.

Por ejemplo: Antigüedad en el trabajo. El cero representa que no hay antigüedad.



Ejercicio 3

Clasificar cada una de las variables que se listan e indicar la escala de medición.

- a) Vidal útil de un disco duro
- b) Número de errores cometidos en un código
- c) Máximo nivel educativo materno.
- d) Grado de satisfacción con el servicio de recolección de residuos urbanos (insatisfecho; algo satisfecho; muy satisfecho).
- e) Contenido de cada lata de Coca-Cola.
- f) Altura sobre el nivel del mar.



Presentación de Datos

La presentación de los datos, luego de su recopilación y organización, se puede realizar a través de **tablas** y **gráficos**.

TABLAS: se utilizan para presentar datos en forma ordenada.

Deben constar de:

Título (que debe responder a las preguntas: ¿Qué? ¿Cómo? ¿Dónde? ¿Cuándo?)

Encabezado: indica cual es el contenido de las columnas que constituyen la tabla.

Concepto o columna matriz: indica los títulos de las filas cuando se utilizan tablas de doble entrada

Cuerpo: es el área de la tabla donde se vuelcan los datos

Notas al pie: aclaraciones de los datos.

Fuente: Establece la procedencia de los datos manejados.



Gastos de los turistas extranjeros por país de origen. Año 2000

País de origen	Gasto total Miles de u\$s	Cantidad de turistas arribados	Estadía media per cápita Días
Brasil	430.437	466.016	7,0
Chile	399.827	567.967	8,1
Paraguay	374.526	499.831	7,5
Bolivia	70.481	95.109	16,3
Uruguay	236.879	488.007	6,0
Estados Unidos	458.573	280.833	13,5
Resto de América	161.537	122.135	13,7
Europa	628.714	353.983	18,8
Resto del mundo	113.600	75.258	14,0

Fuente: Secretaría de Turismo de la Nación en base a datos del Ministerio de Economía




GRAFICOS


El uso de gráficos es conveniente cuando se requiere realizar una comparación más clara entre los diferentes datos recopilados. Los más utilizados son los gráficos de barras y los diagramas circulares.

Gráfico de barras y de bastones: Se utilizan para representar variables cualitativas o cuantitativas discretas.

Se pueden utilizar barras horizontales siempre que la variable sea cualitativa o geográfica.



Histograma: Se utiliza para representar variables cuantitativas continuas cuyas distribuciones de frecuencias están agrupadas en intervalos de clase. Puede representarse tanto frecuencias absolutas, relativas o porcentajes



Pictogramas: Utilizable en todo tipo de variables, especialmente con las cualitativas; en lugar de dibujar una barra o un rectángulo, se dibuja una figura que hace referencia al problema objeto de estudio.





Diagrama circular o de sectores: Se utiliza para cualquier tipo de variable, en general se representan porcentajes. Se suelen utilizar cuando se desea describir como están distribuidos los datos en la población. Pero es útil siempre que no existan muchas categorías distintas, en caso contrario las diferencias no se destacarían en el total. Nos ayuda a visualizar la importancia relativa de cada categoría respecto del total.



Ejercicio 4

El siguiente gráfico representa las respuestas a una encuesta on-line


a) ¿Cuál es el principal motivo de discriminación percibido por más individuos?

b) ¿Qué porcentaje de encuestados cree que los principales motivos de discriminación se relacionan con el aspecto físico?

c) Si se quisiera destacar más el principal motivo de discriminación percibido, ¿qué tipo de gráfico se podría elegir y qué escala se podría usar?

d) clasificar la variable aleatoria

¿CUÁL ES EL PRINCIPAL MOTIVO POR EL CUAL LOS ARGENTINOS DISCRIMINAMOS?



TABLAS DE FRECUENCIAS

¿Cómo se tabula?

Los datos obtenidos se pueden analizar sin agrupar o agrupados.

Podemos agrupar los datos por variable en serie simple (generalmente cuando las variables son discretas o enteras) o en intervalos de clase (cuando las variables son continuas o toman valores reales). Si en cambio nos interesa trabajar conjuntamente con dos variables, lo ideal es una tabla de contingencia o de doble entrada

En todas las tablas pueden detallarse la siguiente información:

FA: Frecuencia Absoluta, número de repeticiones de la variable

FR: Frecuencia Relativa = f/n

FAA: Frecuencia Absoluta Acumulada, acumula frecuencias por renglón

FRA: Frecuencia Relativa Acumulada, acumula frecuencias relativas por renglón



Los datos corresponden a una muestra de las notas de un curso: 2; 4; 4;4;5;5;7;9

a) Construir una tabla de frecuencias para series simples

b) Construir una tabla con intervalos de amplitud dos.

Construimos la tabla; recordemos

FA: Frecuencia Absoluta, número de repeticiones de la variable

FR: Frecuencia Relativa= f/n

FAA: Frecuencia Absoluta Acumulada, acumula (suma) frecuencias por renglón

FRA: Frecuencia Relativa Acumulada, acumula (suma) frecuencias relativas por renglón

Serie simple

x	FA	FAA	FR	FRA
2	1	1	0,125	0,125
4	3	4	0,375	0,5
5	2	6	0,25	0,75
7	1	7	0,125	0,875
9	1	8	0,125	1
Total	n=8		1	

Intervalos de clase

x	FA	FAA	FR	FRA
2 – 4	1	1	0,125	0,125
4 – 6	5	6	0,625	0,75
6 – 8	1	7	0,125	0,875
8 – 10	1	8	0,125	1
Totales	n=8		1	

Tener en cuenta que en los intervalos el límite inferior del intervalo se considera mientras que el límite superior no. Ejemplo intervalo 2- 4 están todos los datos cuyos resultados son entre 2 y 3,9999999... (nunca 4)



Ejercicio 6

Una investigación analiza la posible relación entre soledad y uso de redes sociales. Para tal fin se interrogó a personas que viven solas y a otras que no, acerca de la cantidad de minutos que suelen dedicarle a las redes sociales diariamente. La siguiente tabla refleja lo que corresponde a lo contestado por las personas que viven solas

- a. Identifique la variable “X” y clasifíquela. Identificar la unidad de análisis ¿Cuántos individuos fueron consultados que viven solos?
- b. Agregue una columna de frecuencias acumuladas y frecuencias relativas e interpretar en lenguaje coloquial el tercer renglón de la tabla.

X	FA
0-20	50
20-40	60
40-60	100
60-80	110
80-100	30



c) Ubicar en la tabla de contingencia la información numérica publicada más arriba, y completar las restantes celdas.

Tiempo en redes sociales	Viven solos	Vive acompañados	Total
Menos de 60 minutos		200	
60 o más minutos			
Total		250	



MEDIDAS ESTADÍSTICAS O RESUMEN



Las medidas **resumen** permiten **resumir** las principales características de un conjunto de datos. Se clasifican:

➤ **Medidas de Posición o Tendencia Central:**

La mayoría de los conjuntos de datos manifiestan una tendencia a agruparse en torno a cierto punto. Buscamos valores que sean en cierto sentido “típicos” de ese conjunto de datos.

➤ **Medidas de Dispersión:**

Miden la diseminación o el desperdigamiento de los datos. Dos conjuntos pueden tener las mismas medidas de tendencia central y diferir notablemente en cuanto a la dispersión

➤ **Medidas de Forma:**

Otra cuestión a tener en cuenta al describir los datos, es la forma o patrones que éstos presentan. Buscamos las asimetrías y valores atípicos, es decir, los valores poco usuales que difieren de la mayoría de los datos.



Medidas de posición central o tendencia central

1. Promedio o media aritmética

Es la medida de tendencia central más conocida y utilizada. La media recibe notación distinta según se trate de una población o de una muestra. Se representa por la letra griega μ cuando el estudio es referido a la población y por $\bar{x}$ (x barra o raya) cuando el estudio es referido a la muestra.

El valor de μ es una constante, es decir un parámetro; mientras que $\bar{x}$ es una variable aleatoria puesto que diferentes muestras extraídas de la misma población tienden a tener diferentes medias.

Ya sea la media poblacional o muestral estas se calculan sumando todos los valores observados y dividiendo por el total.



2. Mediana

La mediana es el valor de la variable que ocupa la posición central, cuando los datos se encuentran ordenados (de mayor a menor o viceversa). Es decir, el 50% de las observaciones tiene valores iguales o inferiores a la mediana y el otro 50% tiene valores iguales o superiores a la mediana.

Se simboliza: Me

Ejemplos

Hallar la mediana de los siguientes datos:

3 – 5 – 12 – 16 – 9

Primero debemos ordenar los datos: 3 – 5 – 9 – 12 – 16

Me=??

Veamos ahora si la cantidad de observaciones es par:

-2 – 3 – 5 – 8 – 12 – 25 ; entonces la mediana se calcula promediando los dos valores centrales Me=??



3. Moda o Modo (Mo)

El modo o moda de una distribución se define como el valor de la variable que aparece con mayor frecuencia, es decir el valor de la variable más se repite. En un gráfico de barras la moda se corresponde con la barra más alta.

Ejemplos

Hallar el modo de:

2 – 5 – 3 – 2 – 3 – 2 – 2 – 5 Mo=2 Si la distribución tiene un solo modo se denomina Unimodal.

3 – 5 – 2 – 5 – 2 – 2 – 3 – 5 Mo= ??

3 – 5 – 2 – 5 – 2 – 2 – 3 – 5 – 3 ¿y en este caso? ¿cuál es el Mo?



Medidas de posición relativas

Así como la mediana divide la distribución en dos partes iguales, existen otras medidas que la dividen en: cuatro partes iguales ellos son los cuartiles, en diez partes iguales son los deciles y aquellos que la dividen en cien partes iguales se denominan percentiles.

Percentiles

Existen noventa y nueve percentiles simbolizados como $P(k)$; donde k representa el porcentaje, por ejemplo $P(33)$ representa el **valor por debajo del cual quedan un 33%** de los valores distribución (previamente ordenados). Entonces $P(50)=Me$



Ejercicio 11

Se realizó el siguiente resumen estadístico de la variable “años de antigüedad en la empresa”

**Media= 10,5 Mo= 8 Mediana= 10 P(20)=3 P(80)= 12
P(90)=15**

Completar sobre la línea de puntos y/o tachar lo que no corresponde del siguiente informe:

La mitad de los empleados tienen una antigüedad de; mientras la antigüedad más frecuente de los empleados es y el 20% de los empleados tienen una antigüedad máxima de años. El P(90) significa

.....



Medidas de Dispersión

Buscan evaluar lo “dispersos” o “distintos” que son los valores de cierta variable. Para esto compara la distancia entre cada valor de variable y el promedio.

Ejemplo introductorio:

Supongamos que tenemos una MUESTRA de las calificaciones de 3 alumnos de los últimos parciales.

Notas alumno A: 4 puntos – 4 puntos – 4 puntos

Notas alumno B: 2 puntos – 4 puntos – 6 puntos

Notas alumno C: 1 punto – 1 punto -10 puntos

¿Qué alumno tiene un rendimiento más parejo?

Si tenemos en cuenta EL PROMEDIO nos daremos cuenta que no podemos llegar a ninguna conclusión porque es el mismo para los tres.

En este ejemplo es fácil ver que alumno de los tres es el mas “estable” o menos “disperso”. Lo podemos ver evaluando cada nota de los parciales de cada alumno.

Alumno A: MENOS disperso (porque siempre se sacó 4. **No tuvo variación**)

Alumno B: MEDIO disperso (tiene una cierta dispersión, **los valores son parecidos**)

Alumno C: MUY disperso (porque las notas que se sacó son **MUY distintas**)



Pero cuando trabajamos con muchos datos es necesarios definir una medida que nos indica que conjunto tiene mayor dispersión.

Si tenemos en cuenta EL PROMEDIO nos daremos cuenta que no podemos llegar a ninguna conclusión porque es el mismo para los tres (4 cuatro) ¿Entonces?

Un primer intento para ver la dispersión puede ser calcular “los desvíos” respecto de la media, es decir, la diferencia en el valor observado y el promedio, $x - \bar{x}$; y luego promediarlos y de esta forma vemos la desviación promedio.

Veamos que pasa con el ejemplo; la nota promedio nos dio 4 en todos los casos.

Notas alumno A: 4 puntos – 4 puntos – 4 puntos

Notas alumno B: 2 puntos – 4 puntos – 6 puntos

Notas alumno C: 1 punto – 1 punto -10 puntos

Calculamos la suma los desvíos para cada alumno:

$$A: (4 - 4) + (4 - 4) + (4 - 4) = 0 + 0 + 0 = 0$$

$$B: (2 - 4) + (4 - 4) + (6 - 4) = -2 + 0 + 2 = 0$$

$$C: (1 - 4) + (1 - 4) + (10 - 4) = -3 - 3 + 6 = 0$$



¿¿¿¿Por qué todos cero????

Porque el promedio es una medida de equilibrio “compensa” todos el peso de los valores que están por debajo de él con el peso de los valores que están por encima de él. ¿¿¿¿Qué hacemos????



Necesitamos “sacar” los negativos; entonces podemos elevar al cuadrado porque el resultado es siempre positivo.

Elevar al cuadrado las desviaciones no da la medida llamada:

VARIANZA.

Simbología: Población: σ^2 Muestra: s^2

Pero al elevar al cuadrado se eleva al cuadrado la unidad de medida; entonces calculamos la raíz cuadrada y obtenemos:

DESVÍO ESTÁNDAR

Simbología: Población: σ Muestra: s



Coeficiente de variación:

Es un estadístico de dispersión que tiene la ventaja de no llevar asociada ninguna unidad, por lo que nos permitirá decidir entre dos muestras, cual es la que presenta mayor dispersión sin necesidad de utilizar la misma unidad de medida. La denotaremos por **C.V.**

$$CV = \frac{\text{Desvío estándar}}{\text{Media}} \cdot 100$$

Si el **CV > 20%** decimos que el conjunto de datos es heterogéneo en cuyo caso la media no es representativa

Si el **CV < 20%** el conjunto de datos es homogéneo y en ese caso, cualquier medida de posición central estudiada es representativa



Ejercicio 14

Se realizó un resumen estadístico con los clics (en miles) obtenidos en una campaña de publicidad digital dirigida a usuarios interesados en productos tecnológicos; se analizaron los datos de 13 campañas y se obtuvo: media= 6.5 mediana =7 modo= 8 desvío estándar=0.50

Dadas las siguientes frases, completarlas con la medida que corresponde

- a) La cantidad de clics mas frecuente es
- b) la mitad de las campañas tuvo más de
- c) la distribución de los datos es (homogénea o heterogénea)
..... porque.....



MEDIDAS DE FORMA.

Al describir un conjunto de datos es necesario considerar la “forma” o los patrones que presenta la distribución de los datos. La distribución de los datos puede ser simétrica o no. Cuando no es simétrica, la distribución se llama asimétrica o sesgada.


Para ver la forma de la distribución podemos ver la gráfica (barra) o bien calcular el

COEFICIENTE DE ASIMETRÍA: $AS = \frac{\bar{x} - Mo}{s}$


Pueden presentarse tres casos: $AS > 0$ $AS < 0$ y $AS = 0$

Si $AS > 0$ la distribución se llama asimétrica positiva, y se verifica: $Mo < Me < \bar{x}$.

(Ejemplo: ingresos)




Si $AS < 0$ la distribución es asimétrica negativa y se verifica: $Mo > Me > \bar{x}$
(Ejemplo: vida útil de una batería).



Si $AS = 0$ (en la práctica es cercano a cero), la distribución es simétrica y se verifica:

$Mo = Me = \bar{x}$ (en la práctica las medidas son aproximadamente iguales $Mo \approx Me \approx \bar{x}$) distribución es simétrica (en general aproximadamente simétrica).

(Ejemplo: consumo de agua).



Ejercicio 13

Una compañía evaluó el tiempo de descarga de un paquete de datos en milisegundos (ms) en diferentes condiciones de red. Se registraron los siguientes estadísticos.

Los resultados fueron modo=22.63 media=24.17 desvío estándar=2.88

- a) ¿es un estudio observacional o experimental?
- b) ¿cuál es la variable estudiada? Clasifíquela
- c) interpretar el desvío estándar
- d) calcular el CV e interpretar el resultado en términos del problema
- e) analizar la asimetría e interpretar.



Para resolver con Jamovi

En una importante tienda de electrodomésticos, si registró la cantidad de Split frío – calor vendidos en el último mes por los vendedores de las sucursales del país; se obtuvo los siguientes datos:

7-7--8-8-8-9-9-9-9-9-10-10-10-11

- a) Escribir en términos del problema la v.a en estudio; clasificarla. Indicar que significa en esta situación la frecuencia absoluta.
- b) ¿Es la media representativa? ¿Por qué?
- c) ¿Cuántos Split vendió como mínimo el 50% de los vendedores?
- d) Calcular e interpretar en términos del problema el $P(80)$.
- e) Graficar la distribución de frecuencias.

