

INFERENCIA ESTADÍSTICA

**PATRICIA
ARNAL**



La **estadística inferencial o inductiva**: proporciona métodos que hacen posible la estimación de una característica de una población o la toma de decisiones con respecto a una población a partir de los valores observados en una muestra extraída de dicha población.

Es en este proceso de búsqueda es cuando se utilizan las técnicas y procedimientos estadísticos para obtener resultados acerca de la población.

➤ *Diseño muestral*

El diseño muestral son el conjunto de estrategias y procedimientos que existen para seleccionar una muestra de una población objetivo de estudio, que cumple con una serie de características estadísticamente deseables que sirven para asegurar niveles establecidos de precisión y mantener en lo posible, la inclusión de errores y sesgos baja.

➤ *Diseño experimental*

La experimentación forma parte natural de la mayoría de las investigaciones científicas e industriales. El diseño experimental es una técnica estadística que permite identificar y cuantificar las causas de un efecto dentro de un estudio experimental. En un diseño experimental se manipulan deliberadamente una o más variables, vinculadas a las causas, para medir el efecto que tienen en otra variable de interés.

Si la experimentación la realizamos en un laboratorio donde podemos controlar gran parte de las causas de la variabilidad, el error experimental será pequeño y habrá poca variación en los resultados del experimento. En cambio si se experimenta en procesos industriales o administrativos la variabilidad será mayor en la mayoría de los casos.

La metodología del diseño experimental se basa en la experimentación; con el objetivo de estudiar si cuando se utiliza un determinado tratamiento se produce cambios en el proceso o no. Para ello se debe experimentar aplicando un tratamiento y no aplicándolo. Si la variabilidad experimental es grande, sólo se detectará la influencia del uso del tratamiento cuando éste produzca grandes cambios en relación con el error de observación.

Definiciones

- **Parámetro:** Es una medida que define una característica de una población, por ejemplo, la media poblacional μ . Los parámetros son valores constantes.
- **Estadístico** Es una medida que define una característica muestral, por ejemplo, la media muestral $\bar{x}$. Los estadísticos son variables aleatorias pues su valor depende de la muestra.
- **Estimador:** Es un estadístico usado para estimar un parámetro desconocido de la población.

Hay dos maneras generales de realizar una inferencia acerca de un parámetro

Podemos *estimar* el valor de un parámetro o bien *probar una hipótesis* respecto de su valor.

ESTIMACIÓN

Estimación: $\begin{cases} \text{Puntual} \\ \text{Intervalos de confianza} \end{cases}$

Estimador puntual	Parámetro a estimar
Media muestral: $\bar{x}$	Media poblacional: μ
Varianza muestral: S^2	Varianza poblacional: σ^2
D. E. muestral: S	D. E. poblacional: σ
Proporción <u>muestral</u> : $\hat{p}$	Proporción poblacional: p

Una de las mayores desventajas de la *Estimación Puntual* es que no permite expresar en ninguna forma el grado de incertidumbre de tal estimación.

Estimación por intervalos de confianza:

Proporciona un rango de valores entre los que tendremos una cierta certeza o nivel de confianza de que nuestro parámetro poblacional desconocido se encuentre en el intervalo.

Para poder hacer inferencia para la media utilizaremos como estimador a la media muestral que cumple con las propiedades de un buen estimador

Distribución de la media en el muestreo

Como sabemos por el TCL, cuando el tamaño de la muestra tiende a infinito, la suma de v.a. independientes, tiende a una distribución normal.

Entonces, cuando el tamaño de la muestra es grande, la v.a $\bar{x}$ tiende a una distribución normal con

$$\text{Media: } \mu(\bar{x}) = \mu\left(\frac{x_1 + x_2 + \dots + x_n}{n}\right) = \frac{1}{n} \mu(x_1 + x_2 + \dots + x_n) \underset{*}{=} \frac{1}{n} \cancel{n} \mu(x) \text{ entonces, } \mu(\bar{x}) = \mu(x)$$

$$\text{Varianza: } \sigma^2(\bar{x}) = \sigma^2\left(\frac{x_1 + x_2 + \dots + x_n}{n}\right) = \frac{1}{n^2} \sigma^2(\underbrace{x_1 + x_2 + \dots + x_n}_*) = \frac{1}{n^2} n \sigma^2(x) \rightarrow \sigma^2(\bar{x}) = \frac{\sigma^2(x)}{n};$$

$$\text{entonces el desvío estándar } \sigma(\bar{x}) = \frac{\sigma(x)}{\sqrt{n}}$$

* Porque todos los valores de x_i tienen la misma media y varianza.

Propiedades de los estimadores

1. Consistencia: Un estimador es consistente si la probabilidad de que este se aproxime al valor del parámetro poblacional ha de incrementarse cuanto mayor sea el tamaño de la muestra
$$P(\text{estimador} \xrightarrow{n \rightarrow \infty} \text{parámetro}) = 1$$
2. Eficiencia: Un estimador es eficiente si tienen una varianza relativamente pequeña; $\sigma(\bar{x}) = \frac{\sigma(x)}{\sqrt{n}}$ disminuye a medida que n aumenta.
3. Suficiencia: un estimador es suficiente cuando toma en consideración la mayor cantidad de datos de la información, por ejemplo la mediana no es eficiente porque considera solo los valores centrales
4. Insesgadez: un estimador es insesgado cuando su promedio o esperanza es igual al parámetro que se desea estimar $E(\text{estimador}) = \text{parámetro}$; por ejemplo la media es insesgada porque $\mu(\bar{x}) = \mu(x)$

DISTRIBUCIÓN T- STUDENT



PATRICIA ARNAL

Sabemos que cuando el tamaño de la muestra es grande por el TCL $\bar{x}$ tiende a una distribución normal y que por medio de la estandarización $z = \frac{\bar{x} - \mu(\bar{x})}{\frac{\sigma(\bar{x})}{\sqrt{n}}} = \frac{\bar{x} - \mu(x)}{\frac{\sigma(x)}{\sqrt{n}}}$ $z \rightarrow N(0,1)$.

¿Qué pasa cuando no conocemos el desvío estándar poblacional y el tamaño de la muestra es pequeño?

Si en z reemplazamos $\sigma(x)$ por su estimador $s(x)$, nos queda la v.a $t = \frac{\bar{x} - \mu(x)}{\frac{s(x)}{\sqrt{n}}}$ pero esta variable aleatoria no sigue una distribución normal cuando el tamaño de la muestra es pequeño (no podemos utilizar el TCL)


No es difícil notar que la media de esta distribución es también cero, ya que $\bar{x}$ es un estimador insesgado de μ , pero tiene mayor dispersión que z ya que tenemos una nueva v.a. que es s , el estimador de σ . Pero como dicho estimador es consistente entonces a medida que n aumenta el valor de $s \rightarrow \sigma$

Por lo tanto podemos afirmar que la distribución resultante no es normal, pues tiene más dispersión que depende del tamaño de muestra. La distribución de este estadístico se llama “distribución t-student” y su variable aleatoria se nota de la siguiente manera $t = \frac{\bar{x} - \mu(x)}{\frac{s(x)}{\sqrt{n}}}$

PATRICIA ARNAL

Características de la distribución “t de Student”

Distribución “t” con
10 grados de libertad




- Es simétrica con respecto al eje de ordenadas y es mas achatada que la distribución normal ya que la dispersión es mayor
- Es una variable aleatoria continua que depende del tamaño de la muestra.
- Se acostumbra a describir las características de la distribución en función del tamaño de la muestra menos “1” (n-1). A este número se lo llama “grados de libertad”. Se simboliza con la letra griega “ ν ” llamada nu $\nu=n-1$
- Grados de libertad; representan una medida del número de observaciones independientes que pueden usarse para estimar el desvío estándar de la población madre.
- La media de la distribución es $\mu(t) = 0$ y la varianza $\sigma^2(t) = \frac{\nu}{\nu-2}$, $\nu > 3$.
- A medida que n aumenta, la distribución t-student y la normal estándar (z) se aproximan, ya que el desvío estándar muestral $s \rightarrow \sigma$

Importante: t es el estadístico apropiado en las inferencias acerca de la media poblacional, cuando **la variable aleatoria proviene de una población normal** y el desvío estándar poblacional es desconocido.

Intervalo de confianza para μ con σ desconocido.

Llamamos nivel de confianza $(1 - \alpha)$ a la probabilidad de que un intervalo construido a partir de la media muestral $\bar{x}$ contenga al verdadero valor de la media (poblacional) es decir estamos seguros de que $(1 - \alpha)$ de cada 100 intervalos calculados a partir de las medias de muestras de tamaño “n” incluirán a “ μ ”. Al valor α se lo llama nivel de significación o riesgo.

Vemos en el gráfico de la distribución “t” con n-1 grados de libertad que: $P\left(-t_{(n-1;1-\frac{\alpha}{2})} < \frac{\bar{x}-\mu}{\frac{s}{\sqrt{n}}} < t_{(n-1;1-\frac{\alpha}{2})}\right) = 1 - \alpha$



Despejando μ de la desigualdad: $-t_{(n-1;1-\frac{\alpha}{2})} < \frac{\bar{x}-\mu}{\frac{s}{\sqrt{n}}} < t_{(n-1;1-\frac{\alpha}{2})}$ obtenemos:

Límite inferior del intervalo: $li = \bar{x} - t_{(n-1;1-\frac{\alpha}{2})} \cdot \frac{s}{\sqrt{n}}$

Límite superior del intervalo: $ls = \bar{x} + t_{(n-1;1-\frac{\alpha}{2})} \cdot \frac{s}{\sqrt{n}}$

Llamamos error muestra o de estimación a : $EM = t_{(n-1;1-\frac{\alpha}{2})} \cdot \frac{s}{\sqrt{n}}$

entonces $li = \bar{x} - EM$ $ls = \bar{x} + EM$




¿Cuál es la diferencia entre un intervalo probabilístico y un intervalo de confianza?

Si calculamos $P(a < \bar{x} < b) = 1 - \alpha$, es decir la probabilidad de que la variable aleatoria $\bar{x}$ asuma un valor entre a y b , decimos que (a, b) es un intervalo probabilístico, y significa que el $1 - \alpha$ % de las muestras de tamaño n , darán como resultado de $\bar{x}$ un valor comprendido entre a y b .


Si en cambio, tenemos valores de a y b tales que $p(a < \mu < b) = 1 - \alpha$, el intervalo (a, b) no es un intervalo probabilístico ya que no tiene sentido dar un recorrido de valores que puede asumir μ (porque μ es constante, asume un único valor). Por lo tanto a este intervalo (a, b) se lo llama intervalo de confianza y significa que $(1 - \alpha)$ % de los intervalos calculados a partir de muestras de tamaño n van a contener al verdadero valor de μ .

Por lo tanto este intervalo nos va a servir para estimar el valor de μ cuando este sea desconocido, y para ello nos vamos a basar en una sola muestra de tamaño n , dicha estimación se va a manejar con un % de riesgo que se denomina α o nivel de significación.

Simulación con Infostat




La gráfica muestra 100 intervalos de los cuales 96 contienen a la media y 4 no (marcados en rojo)



La gráfica muestra 100 intervalos de los cuales 91 contienen a la media y 9 no (marcados en rojo)

La gráfica muestra 100 intervalos de los cuales 95 contienen a la media y 5 no (marcados en rojo)



PATRICIA ARNAL

Ejemplo 1:

Se está probando un nuevo sistema de almacenamiento en red en una empresa. Durante 5 meses, se midió cuántos gigabytes (GB) de datos se transfirieron por mes, obteniéndose los siguientes valores (en GB): 607, 725, 784, 784 y 810.

- a) Estimar con un nivel de confianza del 95% el volumen medio de GB transferidos.
- b) Explique por que es necesaria la aclaración de que las ventas siguen una distribución normal.

Datos: $n=5$; $1-\alpha=0,95 \rightarrow \alpha=0,05 \rightarrow \frac{\alpha}{2} = 0,025 \rightarrow 1 - \frac{\alpha}{2} = 0,975$

Resolución (con fórmula)

1ero calculamos la media y el desvío con Jamovi: $\bar{x} = 742$; $s=81,649$.

Para buscar: $t_{(4;0,975)}$ con Jamovi es similar a buscar fractiles con Normal, seleccionamos T-Distribution y completar

$\nu = df = n-1$ (dejar $\lambda = 0$) en Compute quantile colocar el valor de $1 - \frac{\alpha}{2}$

entonces: $t_{(4;0,975)} = 2,78$

Quantile
x1
2.78

Parameters

df = 4

$\lambda = 0$

Function

☐ Compute probability

x1 = 0

☐ $P(X \leq x1)$

☒ Compute quantile(s)

p = 0.975

☒ cumulative quantile

Calculamos el error muestral $EM = t_{(n-1;1-\frac{\alpha}{2})} \cdot \frac{s}{\sqrt{n}}$

$$EM = t_{(4;0,975)} \cdot \frac{81,649}{\sqrt{5}} \Rightarrow EM = 2,78 \cdot \frac{81,649}{\sqrt{5}} = 10151$$

$$l_i = 742 - 101,51 = 640,49 \quad l_s = 742 + 101,51 = 843,51 \quad IC_{0,95}(\mu) = (640,49; 843,51)$$

Es un 95% probable que el promedio de GB transferidos se encuentren entre \$640,49 y \$843,51

Resolución con el Jamovi

Análisis → Pruebas t → Pruebas t de una Muestra.

Pasar la columna de los datos; tildar Estadísticas Adicionales:

Diferencia de medias: Intervalo de confianza (completar con el nivel de confianza)

Importante en Hipótesis siempre debe estar ≠

Pruebas
☒ t de Student
☐ Factor de Bayes
Valores a Priori
☐ Rangos de Wilcoxon

Hipótesis
Valor de prueba
☒ ≠ Valor de prueba

Estadísticas Adicionales
☒ Diferencia de medias
☒ Intervalo de confianza %
☐ Tamaño del efecto
☐ Intervalo de confianza %
☐ Descriptivas
☐ Gráficas descriptivas

Comprobaciones de Supuestos

Prueba t de una Muestra


						Intervalo de Confianza al 95%	
						Inferior	Superior
		Estadístico	gl	p	Diferencia de medias		
A	T de Student	20.3	4.00	< .001	742	641	843

PATRICIA ARNAL

Intervalos de confianza para las proporciones

Si la v.a x tiene una distribución binomial con parámetros n y p ; recordamos $E(x) = n.p$ $V(x) = n.p.(1-p)$
Cuando “ n ” es suficientemente grande ($n > 30$) por el Teorema Central del Límite, entonces
 $X \approx N(n.p; n.p(1 - p))$

El estimador de p es $\hat{p} = \frac{x}{n}$ entonces $\mu(\hat{p}) = p$ y $\sigma^2(\hat{p}) = \frac{p(1-p)}{n} \rightarrow \sigma(\hat{p}) = \sqrt{\frac{p.(1-p)}{n}}$



Al estandarizar nos queda: $z = \frac{\hat{p}-p}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}}$; ahora debemos encontrar el intervalo alrededor de $\hat{p}$

$-z_{(1-\frac{\alpha}{2})} < \frac{\hat{p}-p}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} < z_{(1-\frac{\alpha}{2})}$; despejando se obtiene los límites del intervalo:

$$l_{i,s} = \hat{p} \pm EM \text{ donde } EM = z_{(1-\frac{\alpha}{2})} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Ejemplo

En una casa de service de T.V. se afirma que al menos el 80% de todas las llamadas de servicio se deben a descomposturas de una cierta plaqueta. Se selecciona aleatoriamente una muestra de 1100 llamadas y se determina de 920 se deben a descomposturas de ese tipo de plaqueta. Hallar un intervalo de confianza del 95% para estimar la proporción de reclamos por la descompostura de la plaqueta. .

Datos: $n= 1100$ $x= 920$ (éxitos) $\hat{p} = \frac{920}{1100} = 0,836$ $1- \alpha=0,95$

Debemos calcular los límites del intervalo; $l_{i,s} = \hat{p} \pm EM$

$$EM = z_{\left(1-\frac{\alpha}{2}\right)} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = z_{0,975} \sqrt{\frac{0,836 \cdot 0,164}{1100}} = 1,96 \cdot 0,0112 = 0,022$$

$$l_i = 0,836 - 0,022 = 0,814 \qquad l_s = 0,836 + 0,022 = 0,858$$

$$IC(0,95) = (0,814; 0,858)$$

Se estima con una probabilidad de 0,95 que la proporción real de reclamos por descompostura de la plaqueta se encuentra entre 0,814 y 0,858.