

Prueba de Hipótesis para datos categóricos


DISTRIBUCIÓN
CHI - CUADRADO

Muchas veces es necesario realizar inferencia sobre las medidas de dispersión, es decir, sobre la varianza y el desvío estándar. Como ya vimos S^2 es un buen estimador de σ^2 .

La v.a. continua: $\chi^2 = \frac{s^2(n-1)}{\sigma^2}$ donde s^2 es la varianza de las muestras aleatorias de tamaño n , provenientes de una **población normal** con varianza σ^2 ; a la variable se la conoce como Chi-cuadrado, donde χ^2 representa la letra griega Ji, y $n-1$ representa los grados de libertad de la distribución Chi-Cuadrado

Características de la distribución Chi – Cuadrado

- La distribución Chi-cuadrado al igual que la distribución t-Student tiene $n-1$ grados de libertad y este es el único parámetro de la distribución ($\nu=n-1$)
- El parámetro determina la forma de la curva, cuando es pequeño la forma es muy sesgada hacia la derecha. A medida que ν crece, la curva va haciéndose cada vez más simétrica, tendiendo a la distribución Normal.
- El área total limitada por la curva y los ejes es 1
- Dado que s^2, σ^2 , y $n-1$ son siempre valores positivos, la variable no puede tomar valores negativos dominio: R^+
- $E(\chi^2) = \nu$ $V(\chi^2) = 2 \nu$
- Es unimodal y el $Mo = \nu - 2$



Prueba de Bondad de Ajuste.

- Una de las aplicaciones más importantes de la distribución χ^2 es la prueba de “Bondad de Ajuste”.
- Es una prueba de concordancia entre una distribución teórica y una distribución muestral.
- Se trata de probar si los datos obtenidos de una muestra se ajustan a una distribución teórica.

Hipótesis Nula:

H_0 : Los datos siguen XX distribución.

Hipótesis alternativa:

H_1 : Los datos no siguen la distribución XX.

- ✓ Se requieren “n” observaciones que se clasifican en “c” categorías.
- ✓ Los datos de la muestra se clasifican en **frecuencias observadas** (o_i), que luego se comparan con las **frecuencias esperadas** (e_i) que se obtienen en base a la distribución especificada en H_0 . *(Las frecuencias esperadas para cada clase deben valer 5 o más en caso contrario se agrupan, es decir $n.p_i \geq 5$).*
- ✓ Si la distribución especificada en H_0 es cierta, entonces las diferencias entre las frecuencias observadas y las frecuencias esperadas ($o_i - e_i$) no deberían ser significativas.

Estadístico de Prueba:


$$\chi_m^2 = \sum_{i=1}^c \frac{(o_i - e_i)^2}{e_i}$$

donde c: es el número de categorías en la muestra.

Condición de Rechazo:

$$CR : \{pv < \alpha\}$$

$$p\text{-}v = P(\chi^2 > \chi_m^2)$$



Ejemplo:

Una empresa que brinda servicios informáticos ofrece tres tipos principales de servicios: Asesoría en ciberseguridad, desarrollo de software, soporte técnico. La empresa desea estudiar y se registra cuántos clientes han solicitado únicamente uno de los tres servicios. Según los datos históricos de la firma muestran que el 40% de los clientes contratan servicios de asesoría en ciberseguridad, el 32% solicita desarrollo de software, y el 28% restante requiere soporte técnico. La gerencia desea verificar si estas proporciones históricas se mantienen, para planificar mejor la asignación de programadores e ingenieros. Este año han registrado 300 contratos nuevos, que se muestran en la siguiente tabla:

Servicio ofrecido	Asesoría ciberseguridad	Desarrollo de Software	Soporte técnico
Servicios contratados	138	87	75


Con un nivel de significación del 4%, ¿se puede concluir que ha habido un cambio en las preferencias de los clientes respecto a los servicios informáticos ofrecidos?

Resolución:

H_0 : la distribución de preferencias de los servicios ofrecidos siguen la distribución histórica.

H_1 : la distribución de preferencias de los servicios ofrecidos no siguen la distribución histórica

En Jamovi, ingresamos los datos en una columna las categorías y en la otra las frecuencias observadas
En Recuento seleccionamos N resultados χ^2 de bondad de ajuste



Variable A	Variable B	Variable C
ciber		138
soft		87
soporte		75


Prueba para la Proporción en Una Muestra

2 Resultados
Prueba binomial

**N Resultados
 χ^2 de bondad de ajuste**

Pasamos la variable y la frecuencia → Proporciones Esperadas
En Razón colocamos las proporciones (o probabilidades)
dadas de dato

Nota: al ingresar los datos tildamos frecuencias esperadas, la calcula y la muestra en la tabla



Variable

→ A

Frecuencias (opcional)

→ B

☒ Frecuencias esperadas

Proporciones Esperadas

Nivel	Razón
ciber	0.4
soft	0.32
soporte	0.28

Nos devuelve el pv y el valor muestral $\chi^2_m=4,51$, los gl= $\nu=2$
Se verifica que $pv=P(\chi^2>\chi^2_m; \nu = (\text{categorías}-1)) =0,105$

CR: $\alpha > pv \rightarrow 0,04 \nless 0,105$ No RHo

Conclusión: Los datos no muestran evidencia suficiente para concluir que las proporciones históricas se han modificado, con un nivel de error del 4%

	Frecuencias observadas	p_i	Frecuencias Esperadas $e_i=n.p_i$
A. Ciberseguridad	138	0,4	120
D. Software	87	0,32	96
Soporte técnico	75	0,28	84
Total (n)	300		

Nivel		Frecuencia	Proporción
ciber	Observado	138	0.460
	Esperado	120.0	0.400
soft	Observado	87	0.290
	Esperado	96.0	0.320
soporte	Observado	75	0.250
	Esperado	84.0	0.280

χ^2 de Bondad de Ajuste

χ^2	gl	p
4.51	2	0.105

Prueba de Independencia.

Queremos saber si existe relación entre dos características en las que se clasifica una población. Cada una de esas características es una variable aleatoria y está dividida en cierto número de categorías; por ejemplo: ¿Existe relación entre ser fumador y la predisposición a contraer enfermedades cardíacas? ¿Existe relación entre el nivel de ingresos y el hecho de estar a favor o en contra de una reforma fiscal?

Con esta prueba solo indica si existe o no una relación entre las variables, pero no indica el grado o el tipo de relación; es decir, no indica el porcentaje de influencia de una variable sobre la otra o la variable que causa la influencia, entonces nuestras hipótesis estadísticas son:

H_0 : Las variables son independientes.

H_1 : Las variables no son independientes.

.

Bajo la hipótesis nula de independencia se desea saber si existe una diferencia suficiente entre las frecuencias que se observan y las correspondientes frecuencias que se esperan, si dicha diferencia es grande se rechazará la hipótesis nula.

El estadístico de prueba se calcula :
$$\chi^2_m = \sum_{i=1}^r \sum_{j=1}^c \frac{(o_{ij} - e_{ij})^2}{e_{ij}}$$

Si las proporciones se mantienen entonces las diferencias ($o_{ij} - e_{ij}$) deben ser pequeñas, entonces al igual que en las pruebas de bondad de ajuste, se trata de una prueba unilateral derecha.

Observaciones:

- ✓ Cada rasgo o característica esta clasificado en por lo menos 2 categorías excluyentes y exhaustivas.
- ✓ Cuando una muestra se clasifica en dos variables con categorías excluyentes y exhaustivas.
- ✓ La tabla está formada por las frecuencias que se observaron para cada una de las categorías de las dos variables.

Práctico 8 - Ejercicio 2

Una importante empresa de desarrollo de software está considerando implementar un nuevo sistema de testing automatizado. Antes de tomar una decisión, consultan a sus empleados para conocer su opinión al respecto. Se desea analizar si la postura frente a la automatización del testing depende del nivel de experiencia del profesional.

Se encuestó a 250 empleados, agrupados por nivel de experiencia, y se les pidió que indicaran si estaban a favor, en contra o indecisos respecto a implementar el nuevo sistema.

Años de experiencia/voto	A favor	En contra	indeciso s	Totales
Menos de 2 años (G1)	38	29	9	76
2 a 5 años (G2)	30	42	7	79
Mas de 5 años (G3)	32	59	4	95
Totales	100	130	20	250

- Hallar el valor esperado de accionistas que votaron a favor y tienen mas de 5 años.
- ¿Se puede decir que el voto de los accionistas es independiente de la cantidad de acciones que posee? Plantee hipótesis, CR; considere que el valor muestral resulta ser 10,7957. Utilizar un nivel de significación del 5%.

¿Cómo calculamos las frecuencias esperadas?

Si la preferencia de los años de experiencia es independiente del tipo de voto, sabemos que cuando dos sucesos son independientes se verifica: $P(A \cap B) = P(A) \cdot P(B)$; entonces:

Años de experiencia/voto	A favor	En contra	indecisos	Totales
Menos de 2 años (G1)	38	29	9	76
2 a 5 años (G2)	30	42	7	79
Mas de 5 años (G3)	32	59	4	95
Totales	100	130	20	250

Por ejemplo para calcular la frecuencia esperada de G3 y voto a favor (F) (e_{31}); nos queda:

$$P(G3) = \frac{95}{250} \quad P(F) = \frac{100}{250} \quad \text{y} \quad P(G1 \cap F) = \frac{e_{31}}{250} \rightarrow \frac{e_{31}}{250} = \frac{95}{250} \cdot \frac{100}{250}; \quad \text{despejando} \quad e_{31} = \frac{95}{250} \cdot \frac{100}{250} \cdot 250$$

$$\rightarrow e_{31} = \frac{95 \cdot 100}{250} = 38$$

$$\text{Generalizando: } e_{ij} = \frac{\text{total fila } i \cdot \text{total columna } j}{n}$$

Resolución:

Ho: El voto es independiente de los años de experiencia

H1: El voto no es independiente de los años de experiencia

El ejercicio nos da de dato $\chi^2_m = 10,7957$; $gl = (filas-1)*(col-1)$
calculamos $p_v = P(\chi^2 > 10,7957, gl=2*2=4) = 0,029$

CR: $p-v < \alpha \rightarrow p-v = 0,029 < 0,05$


Los datos muestran evidencia suficiente para concluir que el voto y los años de experiencia están relacionados, con una probabilidad de error de 0,05.

Resolución con JAMOV

JAMOVİ

Ingresamos
los datos de la
siguiente forma:

	 A	 B	 C
1	G1	F	38
2	G1	C	29
3	G1	I	9
4	G2	F	30
5	G2	C	42
6	G2	I	7
7	G3	F	32
8	G3	C	59
9	G3	I	4



Recuento seleccionamos
Prueba de independencia χ^2

Pasamos las variables, elegimos cual ponemos en fila y cual en columna, y las frecuencias. En hipótesis marcamos. Grupo 1 > Grupo 2
En celdas, podemos marcar Frecuencias esperadas, para que las calcule

Tablas de Contingencia

		B			Total
		F	C	I	
G1	Observado	38	29	9	76
	Esperado	30.4000	39.5200	6.0800	76.0000
G2	Observado	30	42	7	79
	Esperado	31.6000	41.0800	6.3200	79.0000
G3	Observado	32	59	4	95
	Esperado	38.0000	49.4000	7.6000	95.0000
Total	Observado	100	130	20	250
	Esperado	100	130	20	250

Pruebas de χ^2

	Valor	gl	p
χ^2	10.7957	4	0.0290
N	250		

Nos devuelve el $\chi^2_m = 10,7957$, los $gl = v = 4$
 $p_v := P(\chi^2 > 10,7957) = 0,029$

Filas

→ A

Columnas

→ B

Frecuencias (opcional)

→ C

Capas

→

Estadísticas

Pruebas

☒ χ^2

☐ χ^2 con corrección de continuidad

☐ Razón de Verosimilitud

☐ Test exacto de Fisher

☐ Prueba z para diferencia de 2 proporciones

Hipótesis

☐ Grupo 1 = Grupo 2

☒ Grupo 1 > Grupo 2

☐ Grupo 1 < Grupo 2

Nominal

☐ Coeficiente de contingencia

☐ Phi y V de Cramer

Ordinal

☐ Gamma

☐ Tau b de Kendall

☐ Mantel-Haenszel

Celdas

Frecuencias

☒ Frecuencias observadas

☐ Frecuencias esperadas

Porcentajes

☐ Fila

☐ Columna

Medidas Comparativas (solo 2x2)

☐ Razón de odds

☐ Log razón de odds

☐ Riesgo relativo

☐ Diferencia de proporciones

☐ Intervalos de confianza

Intervalo 95 %

Comparar filas

Pruebas de Homogeneidad

Otra aplicación de la prueba chi –cuadrado consiste en comprobar la homogeneidad de distintas muestras de una variable. Se toman **k muestras**, de otras tantas poblaciones; en la que **se observa una misma variable aleatoria dicotómica** con r categorías y se desea comprobar si las poblaciones son homogéneas, es decir si la variable tiene la misma distribución en todas ellas.

En estas pruebas no se trata de establecer si las proporciones observadas siguen una distribución; si no de constatar si **una variable categórica** tiene la misma distribución en **dos o más poblaciones** distintas; es decir si las proporciones de cada una de sus categorías son iguales en las distintas poblaciones. No se hace ninguna aseveración respecto del verdadero valor de las proporciones.

En la hipótesis nula suponemos que hay homogeneidad; es decir que las proporciones son iguales.

H_0 : Hay homogeneidad

H_1 : No hay homogeneidad

Observaciones:

- ✓ Cada rasgo o característica esta clasificado en por lo menos 2 categorías excluyentes y exhaustivas.
- ✓ Se observa 1 variable aleatoria y se toman 2 o más muestras con categorías excluyentes y exhaustivas.
- ✓ Queda construida una tabla que está formada por las frecuencias que se observaron en cada categoría de la variable.

Práctico 8 - Ejercicio 4

Una empresa empaca uno de sus productos en cajas de 3 tamaños cada una en distinta línea de producción. El ingeniero de control de calidad ha observado los siguientes defectos: Mancha en la caja; grieta en caja; falta de refuerzo. Se selecciona una muestra de 255 cajas observando los defectos antes mencionados en cada línea de producción. Los datos se expresan en la siguiente tabla:

	TIPO DE DEFECTO				TAMAÑO DE LA MUESTRA
		Mancha	Grieta	Refuerzo	
LINEA DE PRODUCCIÓN	1	45	32	23	100
	2	31	21	18	70
	3	34	27	24	85
	TOTAL	110	80	65	

¿Puede concluirse con estos datos, que existe diferencias en el tipo de defecto según la línea de producción? Utilizar $\alpha=0,05$

Resolución:

Se observa una variable aleatoria categórica: tipo de defecto según la línea de producción; entonces es una prueba de homogeneidad:

Ho: El tipo de defecto no difiere según la línea de producción (es homogéneo)

($P_{1M} = P_{2M} = P_{3M}$; $P_{1G} = P_{2G} = P_{3G}$ $P_{1R} = P_{2R} = P_{3R}$)

H1: El tipo de defecto difiere según la línea de producción (alguna igualdad no se cumple).

Pruebas de χ^2			
	Valor	gl	p
χ^2	0.850	4	0.932
N	255		

$$\chi^2_m = 0,85, \text{ los gl} = v = 4; \text{ gl} = (\text{filas}-1) * (\text{col}-1))$$

$$pv := P(\chi^2 > 0,85) = 0,932$$

CR: $\{pv < \alpha \text{ no se verifica CR; No Rho}$

Asumiendo un nivel de significación del 5% podemos concluir que no existen pruebas suficientes para afirmar que existe diferencias en el tipo de defecto según la línea de producción